

# INFERÊNCIAS SOBRE QUALIDADE DO PROCESSO


## Aula 05

Profa. Carmela Maria Polito Braga – DELT/EEUFMG

# ESTATÍSTICAS E DISTRIBUIÇÕES AMOSTRAIS

A inferência estatística usa quantidades calculadas a partir das observações na amostra.

*Estatística é qualquer função dos dados amostrais que não contenha parâmetros desconhecidos.*



Se a distribuição de probabilidade da população de onde foi tirada a amostra é conhecida, pode-se determinar a distribuição de probabilidade de várias estatísticas calculadas a partir dos dados amostrais.

*A distribuição de probabilidade de uma estatística é chamada de distribuição amostral.*

# AMOSTRANDO DE UMA DISTRIBUIÇÃO NORMAL

## Distribuição Chi-quadrada ( $\chi^2$ )


Do teorema do limite central sabemos que qualquer que seja a distribuição da população, a distribuição do somatório de  $x_i$  é aproximadamente normal com média  $n\mu$  e variância  $n\sigma^2$ . Então a distribuição amostral da média amostral para qq distribuição de população é:

$$\bar{X} \approx N\left(\mu, \frac{\sigma}{n}\right)$$

Ou seja, a média amostral,  $\bar{X}$ , tem distribuição Normal,  $N(\mu, \sigma/\sqrt{n})$

$$\text{Se } y = x_1^2 + x_2^2 + x_3^2 + \dots x_n^2 \Rightarrow f(y) = \frac{1}{2^{n/2} \Gamma(n/2)} y^{(n/2)-1} e^{-y/2}$$

A distribuição  $\chi^2$  (qui-quadrado) é uma importante distribuição amostral da distribuição normal.



Se  $x_1, x_2, \dots, x_n$  são variáveis aleatórias independentes, com média zero e normalmente distribuídas  $N(0,1)$ , então  $y$  tem distribuição  $\chi^2$  com  $n$  graus de liberdade.

Distribuição assimétrica com média  $\mu=n$  e variância  $\sigma^2=2n$ .

# AMOSTRANDO DE UMA DISTRIBUIÇÃO NORMAL

## Distribuição Chi-quadrada ( $\chi^2$ )

Para ilustrar o uso da distribuição  $\chi^2$ , suponha que  $x_1, x_2, \dots, x_n$  seja uma amostra aleatória de uma distribuição  $N(\mu; \sigma^2)$ . Então a variável aleatória

$$y = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2}$$

tem distribuição  $\chi^2$  com  $n-1$  graus de liberdade. Entretanto, usando a equação que define a variância amostral,

pode-se reescrever a equação anterior como:

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

$$y = \frac{(n - 1)S^2}{\sigma^2}$$

A variância amostral, devidamente normalizada, tem distribuição qui-quadrado com  $n-1$  graus de liberdade.

Ou seja, a distribuição amostral de  $\frac{(n - 1)S^2}{\sigma^2}$  é  $\chi_{n-1}^2$


quando a mostra é retirada de uma distribuição normal.

# DISTRIBUIÇÃO T

Outra distribuição amostral importante é a distribuição  $t$ . Se  $x$  é uma variável aleatória normal padrão e se  $y$  é uma variável aleatória  $\chi^2$  com  $k$  graus de liberdade, e  $x$  e  $y$  são independentes, então a variável aleatória 
$$t = \frac{x}{\sqrt{y/k}}$$

tem distribuição  $t$  com  $k$  graus de liberdade. A distribuição de probabilidade de  $t$  é


$$f(t) = \frac{\Gamma[(k+1)/2]}{\sqrt{k\pi}\Gamma(k/2)} \left( \frac{t^2}{k} + 1 \right)^{-(k+1)/2} \quad -\infty < t < \infty$$



A distribuição  $t$  de Student aparece no problema de determinação da média de uma população (que segue a distribuição normal) a partir de uma amostra. Neste problema, não se sabe qual é a média ou o desvio padrão da população, mas ela deve ser normal. Supondo que o tamanho da amostra  $n$  seja muito menor que o tamanho da população, temos que a amostra é dada por  $n$  variáveis aleatórias normais independentes  $X_1, \dots, X_n$ , cuja média  $\bar{X}$  é o melhor estimador para a média da população.

# DISTRIBUIÇÃO T

- A distribuição  $t$  de Student varia de acordo com a dimensão da amostra que vai determinar o número de graus de liberdade.
- A curva da distribuição  $t$  de Student tem a mesma forma em sino da distribuição Normal, mas reflete a maior variabilidade (com curvas mais alargadas, caldas mais longas), esperado em amostras pequenas.
- A distribuição  $t$  de Student tem valor médio zero (tal como a distribuição Normal padrão).
- O desvio padrão da distribuição  $t$  de Student varia de acordo com o tamanho da amostra e é maior do que 1 (o que não acontece com a distribuição Normal standard, onde  $\sigma = 1$ ).
- Quanto maior a dimensão da amostra, mais a distribuição  $t$  de Student se aproxima da distribuição Normal.





# DISTRIBUIÇÃO F (DE FISHER)

A outra distribuição amostral baseada em processo normal a ser considerada é a distribuição  $F$ . Se  $w$  e  $y$  são duas variáveis aleatórias independentes com distribuição  $\chi^2$  com  $u$  e  $v$  graus de liberdade, respectivamente, então a razão

$F_{u,v} = \frac{w/u}{y/v}$  tem distribuição  $F$  com  $u$  graus de liberdade no numerador e  $y$  graus de liberdade no denominador. (Mede a razão entre duas qui quadrado. É importante para inferência sobre variâncias.)

Se  $x$  é uma variável aleatória  $F$  com  $u$  graus de liberdade no numerador e  $y$  graus de liberdade no denominador, então sua distribuição de probabilidade é:

$$f(x) = \frac{\Gamma\left(\frac{u+v}{2}\right)\left(\frac{u}{v}\right)^{u/2}}{\Gamma\left(\frac{u}{2}\right)\Gamma\left(\frac{v}{2}\right)} \frac{x^{(u/2)-1}}{\left[\left(\frac{u}{2}\right)x + 1\right]^{(u+v)/2}} \quad 0 < x < \infty$$



# DISTRIBUIÇÃO F

Como exemplo de uma variável aleatória  $F$ , suponha que temos dois processos normais, independentes, tais como  $x_1 \sim N(\mu_1; \sigma_1^2)$  e  $x_2 \sim N(\mu_2; \sigma_2^2)$ .

Seja  $x_{11}, x_{12}, \dots, x_{1n}$  uma amostra aleatória de  $n_1$  observações do primeiro processo normal e seja  $x_{21}, x_{22}, \dots, x_{2n}$  uma amostra aleatória de tamanho  $n_2$  do segundo processo. Se  $S_1^2$  e  $S_2^2$  são as respectivas variâncias amostrais, então:

$$\frac{s_1^2 / \sigma_1^2}{s_2^2 / \sigma_2^2} \sim F_{n_1-1, n_2-1}$$

Este resultado provém diretamente da distribuição amostral de  $S^2$ , discutida anteriormente. A distribuição  $F$  será usada na inferência sobre as variâncias de duas distribuições normais (*distribuição importante na análise de CEP multivariado*).



# INFERÊNCIA ESTATÍSTICA PARA UMA AMOSTRA

As técnicas de inferência estatística podem ser classificadas em duas amplas categorias: estimação de parâmetros e teste de hipóteses.

Uma hipótese estatística é uma afirmativa sobre os valores dos parâmetros de uma distribuição de probabilidade. P.ex., se achamos que o diâmetro de um mancal é 1,5in, podemos expressar esta afirmativa como

Hipótese  
Alternativa

$$H_0 : \mu = 1,5$$

Hipótese  
Nula

$$H_1 : \mu \neq 1,5$$

Neste exemplo,  $H_1$  é uma hipótese alternativa bilateral, pois este especifica o diâmetro médio que pode ser maior ou menor que este valor. Em outros problemas hipóteses unilaterais podem ser mais apropriadas.

# INFERÊNCIA ESTATÍSTICA PARA UMA AMOSTRA

- Os procedimentos de teste de hipótese são muito úteis em vários problemas de CEP. Também formam a base para a maioria das técnicas de CEP que estudaremos a partir de agora.
- Uma parte importante no problema de teste de hipótese é a determinação dos valores dos parâmetros especificados nas hipóteses nula e alternativa. Eles podem ser obtidos:
  - ✓ de evidência ou conhecimento anterior. Frequente em CEP, quando usamos dados históricos para projeto e periodicamente testamos a hipótese de que este valor não mudou;
  - ✓ de alguma teoria ou modelo do processo;
  - ✓ de uma especificação contratual ou de projeto, o que é frequente também.

# INFERÊNCIA ESTATÍSTICA PARA UMA AMOSTRA

- Para testar uma hipótese, toma-se uma amostra aleatória da população em estudo, calcula-se uma estatística de teste apropriada e, então, rejeita-se ou não a hipótese nula  **$H_0$** .
- O conjunto de valores da estatística de teste que levam à rejeição de  **$H_0$**  é chamado de **região crítica** ou **região de rejeição** do teste.
- Dois tipos de erros podem ser cometidos quando testamos hipóteses:
  - a rejeição da hipótese nula quando ela é verdadeira, o que é chamado de **erro tipo I**;
  - a não-rejeição da mesma quando ela é falsa, o que é chamado de **erro tipo II**.

# INFERÊNCIA ESTATÍSTICA PARA UMA AMOSTRA

As probabilidades de ocorrência destes tipos de erro são denotadas como:

$$\alpha = P \{ \text{erro tipo I} \} = P \{ \text{rejeitar } H_0 | H_0 \text{ é verdadeira} \}$$

$$\beta = P \{ \text{erro tipo II} \} = P \{ \text{não rejeitar } H_0 | H_0 \text{ é falsa} \}$$

Pode ser conveniente trabalhar com o poder de um teste, onde:

$$\text{Poder} = 1 - \beta = P \{ \text{rejeitar } H_0 | H_0 \text{ é falsa} \}$$

- Em outras palavras, o **poder** é a probabilidade de **rejeitar corretamente**  $H_0$ .
  - Em controle de qualidade  $\alpha$  é às vezes chamado de **Risco do Fabricante**, por denotar a probabilidade de um lote bom ser rejeitado ou um processo produzindo com qualidade ser rejeitado como produzindo insatisfatoriamente.
  - Já  $\beta$  é às vezes chamado de **Risco do Consumidor**, por denotar a probabilidade de aceitação de um lote de baixa qualidade ou aceitar que um processo produzindo fora da especificação continue em operação.